

# Bandido de k-brazos

Salvador de Haro Orenes  
salvadorde.haroo@um.es

Miguel Vidal García  
miguel.vidalg@um.es

Jose María Belmonte Martínez  
josemaria.belmontem@um.es

9 de marzo de 2025

## Resumen

En este documento se presenta el estudio realizado sobre el problema del bandido de  $k$ -brazos, un modelo fundamental en el campo del aprendizaje por refuerzo. Se han implementado y comparado distintas familias de algoritmos para resolver este problema, evaluando su desempeño en entornos estacionarios mediante simulaciones. En particular, se ha realizado un análisis detallado de la familia de algoritmos  $\varepsilon$ -greedy, explorando sus variantes y su impacto en el equilibrio entre exploración y explotación. Asimismo, se han implementado y evaluado otros métodos, como los basados en Upper Confidence Bound (UCB) y técnicas de ascenso del gradiente.

Los experimentos han sido llevados a cabo en un entorno de simulación basado en el repositorio de GitHub [https://github.com/ldaniel-hm/eml\\_k\\_bandit](https://github.com/ldaniel-hm/eml_k_bandit), adaptando y extendiendo su código para incluir análisis más completos y gráficas ilustrativas del comportamiento de cada algoritmo.

El presente documento resume el trabajo realizado, discutiendo los resultados obtenidos y proporcionando conclusiones sobre la efectividad de cada enfoque.

## 1. Introducción

El problema del bandido de  $k$ -brazos es un modelo clásico en aprendizaje por refuerzo que representa una situación de toma de decisiones secuencial bajo incertidumbre [1]. En este problema, un agente debe seleccionar repetidamente entre  $k$  acciones (o "brazos"), cada una asociada a una distribución de recompensas desconocida. La clave del problema es encontrar un balance óptimo entre exploración y explotación para maximizar la recompensa acumulada [2].

Este problema es relevante en diversos ámbitos, como la optimización de estrategias publicitarias, la selección de fármacos en ensayos clínicos o la asignación de recursos en sistemas distribuidos [3]. Su importancia radica en la necesidad de diseñar algoritmos eficientes que permitan tomar decisiones óptimas en condiciones de incertidumbre.

El presente trabajo tiene como objetivos:

- ▶ Analizar y comparar distintas familias de algoritmos para el problema del bandido de  $k$ -brazos, evaluando su rendimiento en entornos estacionarios.
- ▶ Completar el estudio de la familia de algoritmos  $\varepsilon$ -greedy, investigando su impacto en la exploración y explotación [1].
- ▶ Implementar y evaluar métodos de la familia UCB

(UCB1 y UCB2) [2] y métodos de ascenso del gradiente (Softmax y Gradiente de Preferencias) [1].

- ▶ Presentar resultados experimentales que permitan visualizar las diferencias en desempeño entre los distintos enfoques.

El resto del documento está organizado de la siguiente manera: en la Sección 2 se presenta la formalización matemática del problema y los enfoques existentes en la literatura. En la Sección 3 se describen los métodos utilizados y la implementación de los algoritmos. La Sección 4 presenta los resultados experimentales obtenidos y su análisis. Finalmente, en la Sección 5 se discuten las conclusiones derivadas del estudio y posibles extensiones futuras.

## 2. Desarrollo

### 2.1. Definición formal del problema

Matemáticamente, el problema del bandido de  $k$ -brazos se define de la siguiente manera: en cada instante de tiempo  $t$ , el agente selecciona un brazo  $a_t \in 1, \dots, k$  y recibe una recompensa  $r_t$  cuya distribución depende del brazo seleccionado, es decir,  $r_t \sim P_{a_t}$ . El objetivo del agente es maximizar la recompensa acumulada:

$$R_T = \sum_{t=1}^T r_t, \quad (1)$$

donde  $T$  representa el horizonte temporal.

El desempeño de una política de selección de brazos también puede medirse a través del arrepentimiento o *regret*, definido como [4]:

$$R(T) = T\mu^* - \mathbb{E} \left[ \sum_{t=1}^T \mu_{a_t} \right], \quad (2)$$

donde:

- ▶  $\mu^* = \max_i \mu_i$  representa la recompensa esperada del mejor brazo.
- ▶  $\mu_i = \mathbb{E}[P_i]$  es la recompensa esperada del brazo  $i$ .

Minimizar el regret es uno de los objetivos principales en el diseño de estrategias óptimas para el bandido multi-brazo [2].

### 2.2. Enfoques existentes en la literatura

Existen múltiples estrategias para abordar el problema del bandido de  $k$ -brazos. Entre las más utilizadas destacan:

- ▶ Algoritmos  $\varepsilon$ -greedy [1], que balancean exploración y explotación mediante una probabilidad  $\varepsilon$  de seleccionar un brazo aleatorio. Aunque son simples de implementar, pueden generar un regret mayor si  $\varepsilon$  no está bien ajustado.
- ▶ Métodos basados en *Upper Confidence Bound* (UCB) [2], que estiman la incertidumbre de cada brazo y favorecen aquellos con mayor incertidumbre. UCB1 fue introducido por Auer et al. (2002) y es ampliamente utilizado debido a su eficiencia en la minimización del regret.
- ▶ Técnicas de ascenso del gradiente, como Softmax y Gradiente de Preferencias [1], que modelan la selección de brazos como una distribución de probabilidad adaptable. Son útiles en escenarios donde la relación entre exploración y explotación debe ajustarse dinámicamente.
- ▶ Métodos bayesianos como Thompson Sampling [5], que utilizan distribuciones a priori y actualizan las creencias sobre la recompensa de cada brazo mediante muestreo posterior. Ha demostrado un excelente desempeño en diversos escenarios y es considerado una alternativa competitiva a UCB.
- ▶ Algoritmos basados en procesos de decisión de Markov parciales (POMDPs) [3], que consideran información incompleta y optimizan la selección de acciones en entornos más generales. Son especialmente útiles en problemas donde la estructura de recompensas cambia con el tiempo.
- ▶ Estrategias basadas en refuerzo profundo, donde redes neuronales aproximan la función de valor y permiten decisiones en entornos complejos con alta dimensionalidad. Estos métodos han sido aplicados con éxito en tareas como el aprendizaje en videojuegos y la toma de decisiones automatizada en problemas de inversión financiera.

### 3. Algoritmos

#### 3.1. $\varepsilon$ -greedy

El método  $\varepsilon$ -greedy equilibra la exploración y la explotación mediante un parámetro  $\varepsilon$  que determina la probabilidad de elegir un brazo aleatorio. Su ecuación de selección es:

$$\begin{cases} \text{Explotar: } \arg \max_a Q(a), & \text{con probabilidad } 1 - \varepsilon, \\ \text{Explorar: seleccionar brazo aleatorio,} & \text{con probabilidad } \varepsilon. \end{cases} \quad (3)$$

Las principales características de este algoritmo son:

- ▶ Un  $\varepsilon$  alto favorece la exploración, pero aumenta la probabilidad de seleccionar brazos subóptimos.
- ▶ Un  $\varepsilon$  bajo prioriza la explotación, pero puede hacer que el algoritmo se estanque en una solución subóptima.

#### 3.2. Métodos Upper Confidence Bound (UCB)

Los algoritmos UCB se basan en una estimación optimista de la recompensa esperada de cada brazo, incorporando un término de exploración basado en la incertidumbre de la estimación. Se destacan:

- ▶ **UCB1:** El algoritmo UCB1 utiliza la siguiente ecuación para estimar la recompensa esperada de cada acción:

$$UCB1(a) = Q(a) + c \times \sqrt{\frac{\ln t}{N_t(a)}} \quad (4)$$

donde  $Q(a)$  es la recompensa media obtenida al seleccionar el brazo  $a$ ,  $t$  representa el número total de iteraciones,  $N_t(a)$  es la cantidad de veces que se ha seleccionado el brazo  $a$  hasta el instante  $t$ , y  $c$  es el parámetro de ajuste que controla el grado de exploración.

- ▶ **UCB2:** El algoritmo UCB2 introduce un enfoque basado en épocas, dividiendo el proceso de toma de decisiones en bloques de tiempo crecientes para cada brazo. Su política de selección de brazo se define mediante la ecuación:

$$UCB2(a) = Q(a) + \sqrt{\frac{(1 + \alpha) \ln \left( \frac{e t}{\tau(k_a)} \right)}{2 \tau(k_a)}} \quad (5)$$

donde el número de rondas que se jugará en la época actual se calcula como:

$$\tau(k_a) = \lceil (1 + \alpha)^{k_a} \rceil, \quad (6)$$

siendo  $k_a$  el índice de la época actual para el brazo  $a$ . Durante cada época, el brazo seleccionado se juega repetidamente hasta completar  $\tau(k_a)$  rondas, momento en el cual se actualizan sus estimaciones  $Q(a)$  y su contador  $k_a$ .

Este esquema permite que UCB2 ajuste dinámicamente el balance entre exploración y explotación:

- La explotación se realiza mediante la estimación de la recompensa media  $Q(a)$ .
- La exploración se incorpora a través del término de incertidumbre, que depende de  $\tau(k_a)$  y del parámetro  $\alpha$ .

#### 3.3. Métodos de Ascenso del Gradiente

Los métodos basados en gradiente modelan la selección de brazos como una distribución de probabilidad parametrizada y la ajustan gradualmente en función de la información obtenida. Se destacan dos enfoques principales:

- ▶ **Softmax:** El algoritmo **Softmax** asigna probabilidades de selección a cada brazo según la función Softmax aplicada a sus valores de recompensa estimada. La probabilidad de seleccionar una acción  $a$  en el tiempo  $t$  se define como:

$$\pi_t(a) = \frac{e^{Q_t(a)/\tau}}{\sum_{b=1}^k e^{Q_t(b)/\tau}} \quad (7)$$

donde:

- $Q_t(a)$  es la recompensa media estimada del brazo  $a$  en el instante  $t$ .
- $\tau$  es un parámetro positivo que controla el equilibrio entre exploración y explotación:
  - ★ Si  $\tau$  es grande, las probabilidades son más uniformes, favoreciendo la **exploración**.
  - ★ Si  $\tau$  es pequeño, la probabilidad se concentra en el mejor brazo, favoreciendo la **explotación**.

- **Gradiente de Preferencias:** El algoritmo **Gradiente de Preferencias** implementa una política de selección basada en la siguiente fórmula propuesta por Sutton y Barto (2018):

$$\pi_t(a) = \frac{e^{H_t(a)}}{\sum_{b=1}^k e^{H_t(b)}} \quad (8)$$

donde  $H_t(a)$  representa una preferencia numérica para cada acción  $a$ . A mayor preferencia (no recompensa), con más frecuencia se tomará la acción. A diferencia de métodos como  $\varepsilon$ -Greedy o Softmax clásico, que trabajan con recompensas promediadas, el Gradiente de Preferencias aprende una función de preferencia  $H_t(a)$  para cada acción, ajustándola mediante el Gradiente Estocástico.

Las preferencias no se calculan explícitamente a partir de las recompensas, sino que se actualizan dinámicamente en cada iteración del algoritmo de la siguiente manera:

$$\begin{cases} H_{t+1}(A_t) = H_t(A_t) + \alpha(R_t - \bar{R}_t)(1 - \pi_t(A_t)) \\ H_{t+1}(a) = H_t(a) - \alpha(R_t - \bar{R}_t)\pi_t(a), \quad \forall a \neq A_t \end{cases} \quad (9)$$

donde:

- $H_t(a)$  es la preferencia de la acción  $a$  en el instante  $t$ .
- $A_t$  es la acción seleccionada en el instante  $t$ .
- $R_t$  es la recompensa obtenida tras seleccionar  $A_t$ .
- $\bar{R}_t$  es la recompensa promedio hasta el momento.
- $\pi_t(a)$  es la probabilidad de seleccionar la acción  $a$ , calculada con Softmax.
- $\alpha$  es la tasa de aprendizaje.

A diferencia de **Softmax**, este método actualiza las preferencias de selección con base en la recompensa recibida, permitiendo adaptabilidad en entornos no estacionarios.

Estos métodos son especialmente útiles cuando las recompensas no son estacionarias o cuando se requiere exploración adaptativa.

## 4. Evaluación y Experimentos

En esta sección se presentan los experimentos realizados y el análisis de los resultados obtenidos. Se han llevado a cabo cuatro experimentos, cada uno evaluando distintos algoritmos en el problema del bandido de  $k$ -brazos bajo tres escenarios:

- **Distribución normal:**  $\mathcal{N}(\mu, 1)$ ,  $\mu \in [1, 10]$ .
- **Distribución Bernoulli:** cada brazo devuelve éxito (1) o fracaso (0).
- **Distribución binomial:**  $\text{Bin}(n = 10, p)$ ,  $p \in [0, 1, 0, 9]$ , donde la recompensa es el número de éxitos en 10 ensayos independientes con probabilidad  $p$ .

En cada uno de esos escenarios, cada algoritmo se ejecuta 500 veces en un horizonte temporal de 1000 pasos, permitiendo obtener valores promedio para su análisis. En particular, se evalúan dos métricas clave:

- **Porcentaje promedio de selección del brazo óptimo:** mide la frecuencia con la que el algoritmo elige la mejor opción en cada paso de tiempo, asegurando que realmente haya aprendido la estrategia óptima y una posible estrategia sub-óptima.

- **Regret acumulado promedio:** cuantifica la pérdida al no seleccionar siempre el mejor brazo. Si su crecimiento se desacelera o se estabiliza, se concluye que el algoritmo ha aprendido la mejor estrategia.

Los experimentos realizados quedan plasmados en los distintos notebooks que componen el repositorio de GitHub [https://github.com/salvadeharo10/k\\_brazos\\_DHBV](https://github.com/salvadeharo10/k_brazos_DHBV). A continuación, se describen las conclusiones extraídas de los experimentos para cada familia de métodos por separado, y se explicará con mayor detalle, añadiendo visualización de gráficas, los resultados obtenidos en el experimento final, donde se hizo una comparación entre los mejores algoritmos de las distintas familias.

### 4.1. Experimentos $\varepsilon$ -greedy

Se probaron tres algoritmos de la familia  $\varepsilon$ -greedy con valores  $\varepsilon \in 0,0, 0,01, 0,1$ . Los experimentos confirmaron que el valor de  $\varepsilon$  juega un papel fundamental en la exploración y explotación del algoritmo. Las principales conclusiones que se extraen de este experimento son:

- $\varepsilon = 0,0$  no es viable en ningún caso, ya que el algoritmo nunca corrige malas decisiones iniciales; es decir, el algoritmo no explora en ningún momento.
- $\varepsilon = 0,01$  introduce algo de exploración, pero es demasiado conservador y retrasa el aprendizaje del mejor brazo.
- $\varepsilon = 0,1$  ofrece el mejor equilibrio en todos los escenarios, permitiendo un aprendizaje más eficiente que en las otras dos versiones anteriores.

### 4.2. Experimentos con métodos UCB

En esta sección se comentan las principales conclusiones extraídas para los métodos de la familia Upper Confidence Bound (UCB). Estos algoritmos tienen una peculiaridad interesante en comparación con el resto de métodos. Si se observan en la subsección 4.4 de este documento las gráficas de porcentaje de selección óptima de estos algoritmos (por ejemplo, la Figura 1, se aprecia como aparece una alta volatilidad en los primeros instantes de tiempo con un pico máximo. Esto se debe a que, en su implementación, se realiza una inicialización de las acciones (brazos) del bandido, de modo que si se trata de un bandido de, en general,  $k$  brazos, estos métodos aprenden en los primeros  $k$  instantes de tiempo cual es el brazo óptimo y lo explotan en el instante  $k + 1$ .

#### 4.2.1. UCB1

Se evaluaron los valores  $c \in \{0,1,1,5\}$  para analizar su impacto en el rendimiento del algoritmo UCB1 en distintos escenarios.

A partir de los resultados obtenidos, se pueden extraer las siguientes conclusiones:

- **Ajuste dinámico de la exploración:** A diferencia del algoritmo  $\varepsilon$ -Greedy, que introduce exploración de forma aleatoria, UCB1 ajusta dinámicamente la exploración en función de la incertidumbre de cada brazo. Esto permite explorar más cuando la información es escasa y explotar cuando se tiene suficiente confianza en la mejor opción.

- ▶ **Importancia del parámetro  $c$ :** El parámetro  $c$  es crítico, ya que determina el equilibrio entre exploración y explotación. Un  $c$  demasiado bajo conduce a una explotación prematura, mientras que un  $c$  elevado induce una exploración excesiva.
- ▶ **Desempeño óptimo con  $c = 1$ :** Con  $c = 1$ , UCB1 mostró el mejor desempeño, identificando rápidamente el brazo óptimo y manteniendo una alta tasa de selección a lo largo del tiempo, especialmente en entornos con distribuciones normales. Además, la pérdida acumulada promedio (regret) es baja, lo que evidencia una toma de decisiones eficiente.
- ▶ **Comportamiento en distribuciones Bernoulli:** Para distribuciones Bernoulli (donde la recompensa es 0 o 1), se observa que es preferible un enfoque que favorezca la explotación, ya que la exploración excesiva puede impedir alcanzar el óptimo.
- ▶ **Efecto de valores altos de  $c$ :** Valores de  $c$  mayores a 1 inducen una exploración excesiva, lo que se traduce en una baja selección inicial del brazo óptimo. Aunque la tasa de selección mejora con el tiempo, nunca alcanza el rendimiento obtenido con valores moderados, evidenciando que un  $c$  demasiado alto retrasa la explotación del mejor brazo.

En conclusión, UCB1 es una estrategia efectiva para el problema del bandido multibrazo cuando se busca un equilibrio entre exploración y explotación. En distribuciones normales y binomiales, UCB1 logra identificar y explotar rápidamente el mejor brazo. Sin embargo, en distribuciones Bernoulli, su rendimiento disminuye debido a una exploración excesiva en las primeras etapas. En estos casos, métodos alternativos como Thompson Sampling podrían ser más adecuados.

#### 4.2.2. UCB2

Para el algoritmo UCB se testearon diferentes valores del parámetro  $\alpha$ , en particular  $\alpha = 0,1$ ,  $\alpha = 0,5$  y  $\alpha = 0,75$ . Tras analizar los resultados obtenidos en los experimentos, se extraen las siguientes conclusiones sobre el algoritmo UCB2:

- ▶ A diferencia del algoritmo  $\varepsilon$ -Greedy, que introduce exploración de manera aleatoria, UCB2 organiza la exploración en épocas, incrementando progresivamente el número de veces que un brazo es seleccionado dentro de cada período. Esto permite una exploración más eficiente, asegurando que los brazos prometedores sean evaluados en intervalos crecientes antes de centrarse en la mejor opción conocida.
- ▶ El parámetro  $\alpha$  es crítico para el rendimiento del algoritmo, ya que controla el balance entre exploración y explotación.
- ▶ UCB2 con  $\alpha = 0,1$  mostró el mejor desempeño, identificando rápidamente el brazo óptimo y manteniendo una alta tasa de selección del mismo. Este comportamiento se observó particularmente en distribuciones continuas o discretas con mayor granularidad, como la normal y la binomial.
- ▶ Valores altos de  $\alpha$  (ej.  $\alpha > 0,5$ ) prolongan las épocas de exploración, retrasando la explotación del mejor brazo y provocando fluctuaciones en la tasa de selección óptima. Aunque eventualmente el algoritmo converge, la estabi-

lidad tarda más en alcanzarse.

- ▶ Si la prioridad es converger rápidamente al mejor brazo, se recomienda usar valores bajos de  $\alpha$  (ej. 0,1), ya que reducen la exploración excesiva en las primeras etapas.
- ▶ Si se busca mantener exploración a lo largo del tiempo, valores intermedios como  $\alpha = 0,5$  o  $\alpha = 0,75$  pueden ser útiles, aunque generan mayor variabilidad en la selección del brazo óptimo.

En conclusión, UCB2 es una estrategia efectiva para el problema del bandido multibrazo, ya que ajusta dinámicamente la exploración mediante períodos crecientes. Su rendimiento depende del ajuste del parámetro  $\alpha$ , el cual debe seleccionarse en función del equilibrio deseado entre exploración y explotación.

### 4.3. Experimentos de métodos de Ascenso de Gradiente

En los experimentos realizados para evaluar y comparar el rendimiento de los algoritmos Softmax y Gradiente de Preferencias en el problema del bandido de  $k$ -brazos bajo los distintos escenarios se llegaron a las conclusiones que se presentan a continuación.

#### 4.3.1. Softmax

Los resultados obtenidos muestran que el parámetro  $\tau$  en Softmax es determinante para el rendimiento del algoritmo:

- ▶ En **distribuciones normales y binomiales**,  $\tau = 1$  ofreció el mejor equilibrio entre exploración y explotación.
- ▶ En **distribuciones Bernoulli**, valores más bajos de  $\tau$  (ej. 0,5) fueron más efectivos, ya que explorar demasiado no es útil cuando las recompensas son solo 0 o 1.
- ▶  $\tau = 5$  fue consistentemente ineficiente, ya que indujo una exploración innecesaria, aumentando el regret y reduciendo la selección del mejor brazo.

#### 4.3.2. Gradiente de Preferencias

Los experimentos realizados muestran que el rendimiento del Gradiente de Preferencias depende significativamente de la elección del parámetro de tasa de aprendizaje ( $\alpha$ ) y de la naturaleza de la distribución de recompensas:

- ▶ Para distribuciones **continuas o discretas con mayor granularidad** (Normal y Binomial), un valor de  $\alpha = 0,1$  ofrece el mejor equilibrio entre exploración y explotación.
- ▶ En entornos con **recompensas binarias (Bernoulli)**, un valor de  $\alpha = 0,5$  es una mejor opción, ya que evita exploraciones insuficientes y favorece la identificación del mejor brazo.
- ▶ En general, **valores altos de  $\alpha$  ( $\geq 1$ ) deben evitarse**, ya que provocan oscilaciones en la selección de brazos, impidiendo que el algoritmo se estabilice en la mejor opción.

### 4.4. Experimento final: Torneo

En los experimentos previos se ha analizado el desempeño de diferentes familias de algoritmos y sus variantes en el proble-

ma del bandido de  $k$ -brazos. Para cada distribución de probabilidad utilizada en los brazos del bandido, se ha determinado qué algoritmo logra el mejor ajuste de su política.

La pregunta que surge ahora es: **¿qué familia de métodos es la mejor para cada distribución de probabilidad?**

Para responder a esta cuestión, en este experimento final se comparan directamente los mejores algoritmos identificados en los experimentos previos para cada tipo de distribución. A continuación, se presenta una tabla con las configuraciones óptimas de los parámetros para cada algoritmo y distribución:

| Distribución          | Epsilon-Greedy ( $\epsilon$ ) | UCB1 ( $\alpha$ ) | UCB2 ( $\alpha$ ) | Softmax ( $\tau$ ) | Gradiente de Preferencias ( $\alpha$ ) |
|-----------------------|-------------------------------|-------------------|-------------------|--------------------|----------------------------------------|
| Normal                | 0,1                           | 1                 | 0,1               | 1                  | 0,1                                    |
| Bernoulli             | 0,1                           | 0,1               | 0,1               | 0,5                | 0,5                                    |
| Binomial ( $n = 10$ ) | 0,1                           | 1                 | 0,5               | 1                  | 0,1                                    |

Tabla 1: Configuraciones óptimas de los algoritmos para cada distribución de probabilidad.

Al igual que en los experimentos anteriores, la comparación se llevará a cabo mediante dos métricas clave:

- ▶ **Porcentaje promedio de selección del brazo óptimo a lo largo del tiempo.**
- ▶ **Regret acumulado promedio a lo largo del tiempo.**

Siguiendo la metodología habitual, se han diseñado tres experimentos, diferenciados por el tipo de distribución de probabilidad asociada a los brazos del bandido. Los resultados se presentan y analizan en las subsecciones siguientes.

#### 4.4.1. Distribución de probabilidad normal

En primer lugar se analizó el escenario del bandido de brazos que siguen una distribución  $\mathcal{N}(\mu, \sigma = 1)$ ,  $\mu \in [1, 10]$ .




Figura 1: Evolución en el tiempo del porcentaje promedio de selección del brazo óptimo en un escenario de distribución normal.

De la gráfica de la Figura 1, donde se puede apreciar la evolución en el tiempo del porcentaje promedio de selección del brazo óptimo para cada algoritmo evaluado, se extraen las siguientes observaciones:

- ▶ **UCB1 ( $c = 1$ ) y UCB2 ( $\alpha = 0,1$ ) tienen el mejor**

**rendimiento:** Ambos algoritmos alcanzan rápidamente una tasa de selección del brazo óptimo cercana al 100 %. UCB2 (línea morada) converge más rápido en los primeros pasos, lo que indica que explora inicialmente y encuentra rápidamente el mejor brazo. La convergencia de UCB1 (línea roja) es algo más progresiva.

- ▶ **Gradiente de Preferencias ( $\alpha = 0,1$ ) y Epsilon-Greedy ( $\epsilon = 0,1$ ) tienen una convergencia intermedia:** Gradiente de Preferencias (verde) mejora más rápido que Epsilon-Greedy (azul), alcanzando aproximadamente un 80 % de selección del mejor brazo. Epsilon-Greedy muestra una convergencia más lenta y llega a estabilizarse en torno al 75 %, lo que sugiere que introduce demasiada exploración y no explota de manera óptima.
- ▶ **Softmax ( $\tau = 1$ ) tiene el peor desempeño:** La línea naranja muestra que Softmax se queda estancado en torno al 30 % de selección del brazo óptimo. Esto indica que con  $\tau = 1$ , el algoritmo sigue explorando demasiado en lugar de explotar el mejor brazo, por lo que en este escenario no resulta ser muy eficiente.




Figura 2: Evolución en el tiempo del regret acumulado promedio en un escenario de distribución normal.

Si ahora se analiza la evolución del regret acumulado promedio, recogido en la gráfica de la Figura 2, se confirman los resultados comentados anteriormente:

- ▶ **UCB1 ( $c = 1$ ) y UCB2 ( $\alpha = 0,1$ ) tienen el menor regret:** UCB2 (línea morada) tiene el mejor rendimiento, con un regret acumulado prácticamente constante y cercano a cero después de los primeros pasos. UCB1 (línea roja) también muestra un regret muy bajo, indicando que aprende rápidamente a seleccionar el mejor brazo y minimiza las pérdidas.
- ▶ **Gradiente de Preferencias ( $\alpha = 0,1$ ) y Epsilon-Greedy ( $\epsilon = 0,1$ ) tienen un regret intermedio:** Gradiente de Preferencias (línea verde) acumula más regret que UCB, pero menos que Epsilon-Greedy. Epsilon-Greedy (línea azul) muestra un crecimiento lineal en el regret, lo que sugiere que sigue explorando demasiado y no logra explotar completamente el mejor brazo.
- ▶ **Softmax ( $\tau = 1$ ) tiene el peor desempeño:** La línea naranja muestra un crecimiento muy acelerado del regret acumulado promedio, alcanzando valores superiores a 900 al final del experimento. Esto confirma que Softmax

con  $\tau = 1$  no logra explotar el mejor brazo de manera eficiente, lo que provoca grandes pérdidas a lo largo del tiempo.

#### 4.4.2. Distribución de probabilidad Bernoulli

En este escenario de bandido con brazos que siguen una distribución de Bernoulli, donde la recompensa ofrecida es 1 (éxito) o 0 (fracaso) con probabilidad  $p$  aleatoria, los resultados relativos al porcentaje de selección de brazo óptimo se pueden observar en la gráfica de la Figura 3.




Figura 3: Evolución en el tiempo del porcentaje promedio de selección del brazo óptimo en un escenario de distribución Bernoulli.

Las principales observaciones de la gráfica anterior son las siguientes:

- **Gradiente de Preferencias ( $\alpha = 0,5$ ) tiene el mejor rendimiento:** La línea verde muestra que este algoritmo alcanza el mayor porcentaje de selección del brazo óptimo ( $\sim 80 - 85\%$ ). Su enfoque basado en la actualización de preferencias lo hace muy eficaz en problemas con recompensas binarias.
- **UCB1 ( $c = 0,1$ ) también muestra un rendimiento sólido:** La línea roja indica que UCB1 converge rápidamente y alcanza un  $\sim 70\%$  de selección del brazo óptimo. Es un rendimiento inferior al Gradiente de Preferencias, pero sigue siendo una opción viable.
- **Epsilon-Greedy ( $\epsilon = 0,1$ ) y UCB2 ( $\alpha = 0,1$ ) tienen un rendimiento intermedio:** Epsilon-Greedy (línea azul) mejora de forma progresiva, pero no supera el  $65 - 70\%$ . UCB2 (línea morada) muestra fluctuaciones notables y no logra una convergencia estable.
- **Softmax ( $\tau = 0,5$ ) es el peor algoritmo en este caso:** La línea naranja se mantiene muy por debajo del  $30\%$ . Softmax no es eficiente en este escenario, ya que sigue explorando en exceso y no logra explotar el mejor brazo de manera efectiva.

En cuanto al regret acumulado, el cual se puede analizar en la gráfica de la Figura 4, se observan algunas peculiaridades interesantes:

- **UCB1 ( $c = 0,1$ ) y Gradiente de Preferencias ( $\alpha =$**




Figura 4: Evolución en el tiempo del regret acumulado promedio en un escenario de distribución Bernoulli.

**0,5) tienen el menor regret:** La línea roja muestra que este algoritmo logra minimizar el regret de manera más efectiva que el resto, pero en la gráfica de la Figura 3 se ha visto que este algoritmo era superado por Gradiente de Preferencias en cuanto a selección del brazo óptimo. Esto se debe a que UCB1 es el algoritmo que, en este escenario, aprende más rápido cuál es el mejor brazo y lo selecciona con alta frecuencia. Sin embargo, se aprecia como la curva del regret de Gradiente de preferencias (color verde) logra una desaceleración algo mayor que la curva de color rojo relativa a UCB1, por lo que, con el paso del tiempo, Gradiente de Preferencias logra una mayor explotación del brazo óptimo.

- **Epsilon-Greedy ( $\epsilon = 0,1$ ) y UCB2 ( $\alpha = 0,1$ ) acumulan más regret:** Epsilon-Greedy (línea azul) tiene un crecimiento de regret mayor que UCB1 y Gradiente de Preferencias, indicando que sigue explorando demasiado. UCB2 (línea morada) muestra un comportamiento errático, lo que sugiere que su estrategia de exploración por épocas no es óptima aquí por la naturaleza de la distribución de Bernoulli.
- **Softmax ( $\tau = 0,5$ ) nuevamente es el peor algoritmo:** Su línea naranja muestra un crecimiento de regret alarmante, confirmando que no logra explotar correctamente el mejor brazo.

#### 4.4.3. Distribución de probabilidad Binomial

En el tercer y último escenario, donde se tiene un bandido de 10-brazos con brazos que siguen una distribución Binomial  $\text{Bin}(n = 10, p)$ ,  $p \in [0,1,0,9]$ , los resultados obtenidos son muy parecidos a los observados en la distribución Normal.

En cuanto al porcentaje de selección de brazo óptimo, en la gráfica de la Figura 5 se observa lo siguiente:

- **UCB1 ( $c = 1$ ) y UCB2 ( $\alpha = 0,5$ ) son los algoritmos más eficientes:** UCB2 (línea morada) alcanza el  $100\%$  de selección del brazo óptimo en pocos pasos y mantiene un rendimiento estable. UCB1 (línea roja) también alcanza casi el  $100\%$ , pero con una convergencia ligeramente más lenta. Por tanto, el ajuste de la explo-




Figura 5: Evolución en el tiempo del porcentaje promedio de selección del brazo óptimo en un escenario de distribución Binomial.

ración que realizan dinámicamente estos algoritmos en función de la incertidumbre es bastante efectiva en este escenario. **Gradiente de Preferencias ( $\alpha = 0,1$ ) y Epsilon-Greedy ( $\epsilon = 0,1$ ) tienen un rendimiento intermedio:** Gradiente de Preferencias (línea verde) supera el 80 % de selección del mejor brazo, mostrando un buen equilibrio entre exploración y explotación. Epsilon-Greedy (línea azul) mejora gradualmente, pero no logra superar el 75 %, lo que sugiere que introduce demasiada exploración. **Softmax ( $\tau = 1$ ) sigue siendo el peor algoritmo:** La línea naranja se mantiene muy por debajo del 40 %, lo que indica que sigue explorando en exceso. Al igual que en distribuciones normales y Bernoulli, Softmax no logra explotar el mejor brazo de manera eficiente en este contexto.




Figura 6: Evolución en el tiempo del regret acumulado promedio en un escenario de distribución Binomial.

Por último, la gráfica de la Figura 6 muestra la evolución del regret acumulado promedio en el mismo escenario de distribución Binomial, de donde se obtienen las siguientes conclusiones:

- **UCB1 ( $c = 1$ ) y UCB2 ( $\alpha = 0,5$ ) minimizan el regret:** UCB2 (línea morada) tiene el menor regret, lo que indica que rápidamente converge al mejor brazo. UCB1 (línea roja) también logra un regret bajo, aunque ligeramente superior al de UCB2.
- **Gradiente de Preferencias ( $\alpha = 0,1$ ) y Epsilon-Greedy ( $\epsilon = 0,1$ ) tienen un regret intermedio:** Gradiente de Preferencias (línea verde) tiene un regret moderado, pero sigue acumulándolo más que UCB. Epsilon-Greedy (línea azul) acumula más regret que Gradiente de Preferencias, lo que indica que sigue explorando innecesariamente.
- **Softmax ( $\tau = 1$ ) nuevamente es el peor algoritmo:** Su línea naranja muestra un crecimiento de regret excesivo, confirmando su ineficiencia en distribuciones binomiales.

## 5. Conclusiones

Este estudio ha analizado el rendimiento de diversas estrategias para el problema del bandido de  $k$ -brazos, evaluando los métodos  $\epsilon$ -greedy, Softmax, Gradiente de Preferencias, UCB1 y UCB2 en distintos escenarios de distribución de recompensas. Los resultados muestran que los algoritmos basados en Upper Confidence Bound (UCB) fueron los más efectivos en la mayoría de los casos, logrando un equilibrio óptimo entre exploración y explotación. En particular, UCB2 y UCB1 destacaron por su capacidad para minimizar el regret acumulado y alcanzar rápidamente una alta selección del brazo óptimo. Gradiente de Preferencias tuvo un desempeño notable en distribuciones Bernoulli, mientras que  $\epsilon$ -greedy mostró un rendimiento intermedio. Softmax, por su parte, fue el menos eficiente en todos los experimentos, debido a su exploración excesiva.

A pesar de la solidez de estos resultados, el estudio presenta algunas limitaciones. En primer lugar, solo se han evaluado distribuciones específicas de recompensas, lo que deja abierta la posibilidad de probar estos algoritmos en entornos más complejos o no estacionarios. Además, la elección de los hiperparámetros se realizó mediante experimentación manual, por lo que una optimización más exhaustiva podría mejorar el rendimiento de ciertos métodos. Otra limitación es que no se han considerado estrategias adaptativas que ajusten dinámicamente los parámetros de exploración durante la ejecución.

El impacto de este trabajo en el campo del aprendizaje por refuerzo es significativo, ya que proporciona una evaluación detallada de los algoritmos más utilizados en la exploración-explotación. La elección de un buen método es fundamental en aplicaciones como la publicidad en línea, la gestión de inversiones o la optimización de tratamientos médicos, donde la correcta identificación de la mejor opción tiene consecuencias críticas.

Como líneas futuras de investigación, sería interesante estudiar el comportamiento de estos algoritmos en entornos dinámicos donde las recompensas cambian con el tiempo, así como explorar variantes más avanzadas como Thompson Sampling [5] o métodos basados en aprendizaje profundo. También se podrían desarrollar estrategias híbridas que combinen lo mejor de cada enfoque para adaptarse a diferentes tipos de problemas.

blemas. La comparación con enfoques bayesianos o con técnicas de meta-aprendizaje podría proporcionar nuevas perspectivas sobre la eficiencia y aplicabilidad de estos métodos en escenarios del mundo real.

## Referencias

- [1] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [2] Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). *Finite-time analysis of the multiarmed bandit problem*. Machine Learning, 47(2-3), 235-256.
- [3] Gittins, J., Glazebrook, K., & Weber, R. (2011). *Multi-armed bandit allocation indices*. John Wiley & Sons.
- [4] Lai, T. L., & Robbins, H. (1985). *Asymptotically efficient adaptive allocation rules*. Advances in Applied Mathematics, 6(1), 4-22.
- [5] Chapelle, O., & Li, L. (2011). *An empirical evaluation of Thompson sampling*. Advances in Neural Information Processing Systems, 24.